

Fundamentos y Preparación de Datos

Fundamentos de Aprendizaje Automático


Yomin Jaramillo M
yejaramilm@eafit.edu.co

Universidad EAFIT
Medellín 2026




¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

- En los últimos años se han producido avances impresionantes en la inteligencia artificial.
- Muchos de estos avances han sido posibles gracias al aprendizaje automático




¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

- Usamos aprendizaje automático todos los días cuando utilizamos un motor de búsqueda.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

- El aprendizaje automático se utiliza en todos los filtros de spam, como los de Gmail.
- Los sistemas de aprendizaje automático también son utilizados por las compañías de tarjetas de crédito y los bancos para detectar automáticamente comportamientos fraudulentos.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

- Uno de los usos más emocionantes y de vanguardia de los algoritmos de aprendizaje automático es en los vehículos autónomos



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

En **1959**, Arthur Samuel definió el aprendizaje automático de la siguiente manera:

“El aprendizaje automático es un campo de estudio que le da a las computadoras la capacidad de aprender sin ser programadas explícitamente.”


¿Qué significan aquí “aprender” y “programadas explícitamente”?

Veamos un ejemplo.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

Un sistema de conducción autónoma utiliza decenas de componentes que incluyen la detección de automóviles, peatones y otros objetos.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

Una forma de construir un sistema de detección es escribir un conjunto de reglas.




En la práctica, es casi imposible que un ser humano pueda especificar todos los casos límite.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

El enfoque de aprendizaje automático consiste en enseñarle a una computadora cómo realizar la detección mostrándole muchos ejemplos de diferentes objetos.



No se necesita programación manual: la computadora aprende por sí sola qué define a un peatón o a un automóvil.



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

Este principio puede aplicarse a innumerables dominios: diagnóstico médico, automatización de vehículos, traducción automática y muchos más.

"El aprendizaje automático es un campo de estudio que le da a las computadoras la capacidad de aprender sin ser programadas explícitamente."



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

“La inteligencia artificial es el estudio de cómo hacer que las computadoras realicen tareas que, en la actualidad, los humanos hacen mejor.” - Russell y Norvig



¿QUÉ ES EL APRENDIZAJE AUTOMÁTICO?

¿Por qué este enfoque para construir software resulta interesante?


- Nos permite construir sistemas prácticos para aplicaciones del mundo real en las que otros enfoques de ingeniería no funcionan.
- El aprendizaje es ampliamente considerado como un enfoque clave para construir sistemas de inteligencia artificial de propósito general.
- La ciencia y la ingeniería del aprendizaje automático ofrecen conocimientos sobre la inteligencia humana.



Ramas del Aprendizaje Automático


Aprendizaje Supervisado:

El enfoque mas común en Aprendizaje Automático.



Aprendizaje Supervisado:

- Comenzamos recolectando un conjunto de datos de objetos etiquetados.
- Entrenamos un modelo para que produzca predicciones precisas sobre este conjunto de datos.
- Cuando el modelo ve datos nuevos y similares, también será preciso.





Ramas del Aprendizaje Automático

Aprendizaje Supervisado:

Aplicaciones:


- Clasificación de imágenes médicas.
- Detección de SPAM.
- Detección de objetos en la conducción autónoma.
- Reconocimiento de imágenes.
- Análisis de sentimiento.



Ramas del Aprendizaje Automático

Aprendizaje No Supervisado:


Aquí tenemos un conjunto de datos sin etiquetas. Nuestro objetivo es aprender algo interesante sobre la estructura de los datos.



Ramas del Aprendizaje Automático

Aprendizaje No Supervisado:

Training



Input: Images (without labels)

Output: Model that finds similar groups (clusters)



Deployment



Input: Image

Output: group




Ramas del Aprendizaje Automático

Aprendizaje No Supervisado:


Aplicaciones:

- Sistemas de recomendación: sugerir películas en Netflix.
- Segmentación de clientes
- Detección de anomalías y valores atípicos: identificar ataques cibernéticos a infraestructura crítica.
- Procesamiento de señales: extraer voz humana limpia a partir de una grabación de audio con ruido.
- Mantenimiento Predictivo: Sensores en turbinas de aviones que detectan una vibración fuera de lo normal antes de que la pieza se rompa.




Aprendizaje por refuerzo:

En el aprendizaje por refuerzo, un agente interactúa con el mundo a lo largo del tiempo. Le enseñamos un buen comportamiento proporcionándole recompensas



Ramas del Aprendizaje Automático

Aprendizaje por refuerzo:



Ramas del Aprendizaje Automático

Aprendizaje por refuerzo:

Aplicaciones:

- Crear agentes que juegan juegos como Ajedrez o Go.
- Drones Autónomos: Aprender a mantener el equilibrio ante ráfagas de viento o a navegar por espacios estrechos sin chocar.
- Locomoción: Google DeepMind ha logrado que robots bípedos aprendan a caminar, correr y saltar sobre terreno irregular simplemente dándoles una "recompensa" por avanzar sin caerse.




IA y DEEP LEARNING

El aprendizaje automático está estrechamente relacionado con estos dos campos.


IA: Se refiere a cualquier técnica que permita a las computadoras imitar el comportamiento humano.

Aprendizaje automático: en lugar de escribir reglas a mano, le damos datos a la máquina para que ella misma descubra los patrones.

Aprendizaje profundo: se inspira en la estructura del cerebro humano utilizando redes neuronales artificiales con muchísimas capas (de ahí lo de "profundo").



Naturaleza Interdisciplinaria de la Ciencia de Datos



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>



Naturaleza Interdisciplinaria de la Ciencia de Datos

Matemáticas y Estadística:

- Álgebra Lineal
- Cálculo
- Probabilidad
- Análisis descriptivo, inferencial, predictivo y prescriptivo.

Informática:

- Bases de datos
- Procesar y manipular datos
- Desarrollo e implementación de algoritmos y modelos
- Despliegue y mantenimiento de soluciones
- Seguridad

Experiencia empresarial y en el área de aplicación:

- Formulación del problema
- Adquisición y comprensión de datos relevantes
- Interpretación y comunicación de resultados



Historia


Siglo XX:

1946: Surge la 1ra computadora electrónica digital de proposito general (ENIAC).

1956: Nacimiento formal del termino-Inteligencia Artificial (John McCarthy)

Conferencia Dartmouth

1962: Artículo “The Future of Data Analysis” (John W. Tukey)
Enfoque practico.



Fuente: <https://emeritus.org/in/learn/what-is-artificial-intelligence/>



Historia

Siglo XX:

1974: Nacimiento del término
"Data Science"

(Peter Naur).

Libro: "Concise Survey of
Computer Methods"

1989: Primer taller sobre
"Knowledge Discovery in
Databases (KDD)" (minería de
datos).

1990: Proliferación de
Algoritmos.

Árboles de decisión, SVM,
Redes Neuronales
(retropropagación).

1997: IBM Deep Blue derrotó a
Kasparov.



Fuente: <https://www.bigdatawire.com/2017/08/31/continuing-data-science-education/>



Fuente: <https://datascientest.com/en/all-about-deep-blue>



Historia

Siglo XXI:


2001: La Ciencia de Datos como disciplina independiente.

Estadística + Computación.

2006 – 2009: Auge del “Big Data” gracias a Google, Amazon y Yahoo!.

2008: El “**Científico de Datos**” nace formalmente.

D.J. Patil (LinkedIn) y Jeff Hammerbacher (Facebook).



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>



Historia

Siglo XXI:

2010: Democratization y expansion.

Ciencia de Datos → Profesion mas sexy
del siglo XXI.

Popularizacion de Python + librerias para ciencia de datos.

Resurgimiento del Aprendizaje Profundo (Deep Learning)

Gracias a:

Aumento de capacidad computacional (GPUs).


Disponibilidad de grandes conjuntos de datos.



Fuente: <https://www.create-learn.us/blog/data-science-for-children/>



Ciclo de vida de un sistema de Aprendizaje Automático



Este ciclo de vida sigue la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining).



Ciclo de vida de un sistema de Aprendizaje Automático

Fase del Ciclo de Vida	Objetivo Principal	Actividades Clave
1. Comprensión del Negocio	Definir el problema y los objetivos del negocio que los datos pueden resolver.	Entender requisitos, establecer métricas de éxito, evaluar viabilidad.
2. Comprensión de los Datos	Explorar y evaluar la calidad y relevancia de los datos disponibles.	Recopilar datos iniciales, descripción de datos (EDA), verificación de calidad.
3. Preparación de los Datos	Limpiar, transformar y organizar los datos para el modelado.	Manejo de valores faltantes/outliers, transformación, ingeniería y selección de características.
4. Modelado	Seleccionar y aplicar algoritmos para construir el modelo.	Elegir algoritmo, dividir datos, entrenar modelo, ajustar hiperparámetros.
5. Evaluación del Modelo	Determinar la calidad, precisión y utilidad del modelo.	Calcular métricas de rendimiento, validación cruzada, interpretar resultados, revisión con negocio.
6. Despliegue y Monitoreo	Poner el modelo en producción y asegurar su funcionamiento continuo.	Implementar el modelo, monitorear rendimiento, mantenimiento y reentrenamiento.



Roles clave

Rol	Enfoque Principal	Responsabilidades Clave	Habilidades Típicas	Metáfora
Data Engineer	Construir y mantener la infraestructura de datos.	Diseñar y optimizar bases de datos, crear pipelines ETL/ELT, asegurar la calidad de datos.	SQL, Python/Java/Scala, Bases de Datos (SQL/NoSQL), Big Data (Hadoop, Spark), Cloud.	El Arquitecto y Fontanero que construye las tuberías de datos.
Data Analyst	Interpretar datos históricos para insights de negocio.	Limpiar y preprocesar datos, análisis descriptivo, crear informes y dashboards, visualización.	SQL, Herramientas BI (Tableau, Power BI), Excel, Estadística Descriptiva, Comunicación.	El Periodista de Datos que explica lo que pasó y por qué.
Data Scientist	Construir modelos predictivos y prescriptivos.	Definir problemas de negocio, EDA, ingeniería de características, construir y validar modelos ML.	Matemáticas, Estadística, Python/R, Machine Learning, Conocimiento de Negocio, Comunicación.	El Científico y Meteorólogo que predice el futuro y aconseja.
ML Engineer	Poner modelos ML en producción y optimizarlos.	Desplegar modelos en sistemas, construir pipelines MLOps, monitorear y optimizar el rendimiento.	Ingeniería de Software, Python, Sistemas Distribuidos, MLOps (Docker, Kubernetes), Frameworks ML.	El Ingeniero de Sistemas que hace que las predicciones sean operativas.



Tarea

Leer el documento “lecturaCasosCicloVida.pdf”



Contenido

1. Token embeddings
2. Positional encodings
3. Sequence modeling
4. Recurrent neural networks
5. Attention



