

Lectura 2: Casos de estudio ciclo de vida de un sistema de aprendizaje automático

26 de enero de 2026

1. Caso de Estudio 1: Retención de Clientes (Churn)

Una importante empresa de telefonía móvil contrata a un equipo de ciencia de datos para reducir el churn (pérdida de clientes). El equipo decide implementar el siguiente flujo de trabajo:

- Entendimiento del Negocio: Se define que el objetivo es identificar clientes con alta probabilidad de cancelar su plan para ofrecerles un descuento.
- Entendimiento de Datos: Se extraen 2 años de historial de llamadas, quejas, pagos y uso de datos.
- Preparación de Datos: El equipo realiza una limpieza impecable, maneja valores nulos y crea variables ingeniosas (Feature Engineering), como el "promedio de minutos consumidos en los últimos 3 meses".
- Modelado: Entrenan un modelo XGBoost que alcanza un 92 % de precisión (Accuracy) y un F1-Score del 0.89. Técnicamente, el modelo funciona muy bien.
- Evaluación: Se valida el modelo con datos de prueba y los resultados se mantienen estables. El equipo celebra el éxito técnico.
- Despliegue: El modelo se pone en producción. Cada vez que detecta un cliente en riesgo, el sistema envía automáticamente un mensaje de texto (SMS) con un cupón de 20 % de descuento para los próximos 3 meses.

1.1. Resultado

Tres meses después, el reporte financiero muestra que la tasa de cancelación no bajó, pero el margen de ganancias cayó un 15 %. Al investigar, descubren que muchos clientes que recibieron el cupón no tenían intención de irse, pero aceptaron el descuento felices, mientras que los que sí pensaban irse, ni siquiera abrieron el SMS porque ya habían contratado a la competencia.

1.1.1. Error Cometido

Se suele decir que "el modelo estaba mal" o "los datos eran viejos". Sin embargo, aquí el fallo es más profundo y se sitúa en los siguientes dos puntos clave:

- Fallo Principal (Fase de Evaluación/Business Understanding): El equipo evaluó el éxito del modelo por su precisión técnica (92 %) y no por su impacto en el negocio. No realizaron una prueba A/B (piloto) para ver si la intervención (el SMS con descuento) realmente cambiaba el comportamiento del cliente.
- Fallo de Dominio: Ignoraron el canal de comunicación. Un SMS es un canal frío para alguien que ya está decidido a irse.

1.2. Solución Propuesta

1.2.1. Cambiar de “Churn” a “Uplift”

El error fue predecir quién se va. El éxito es predecir a quién puedo convencer de que se quede. En ciencia de datos esto se llama Uplift Modeling.

- Existen clientes que se quedarán hagamos algo o no (Sure Things).
- Clientes que se irán hagamos algo o no (Lost Causes).
- Objetivo: Identificar a los “Persuadibles”. Darle un descuento a un “Sure Thing” es regalar dinero (lo que pasó en el caso).

1.2.2. Implementar un Experimento Controlado (A/B Testing)

Antes del despliegue masivo, el equipo debió pasar por una fase de Evaluación de Negocio rigurosa:

- Grupo de Control: 50 % de los clientes identificados como “en riesgo” no reciben nada.
- Grupo de Tratamiento: 50 % recibe el SMS con el descuento.
- Resultado: Si la tasa de fuga es igual en ambos grupos, el modelo funciona pero la acción (el descuento por SMS) es inútil. Esto se detecta en una semana, no en tres meses.

1.2.3. Análisis de Causalidad e Intervención Multi-canal

En lugar de un SMS genérico (que suele ser ignorado), la analítica Prescriptiva sugeriría acciones diferenciadas:

- Para el cliente de alto valor: Una llamada personalizada del centro de retención.
- Para el cliente que usa pocos datos: Un aumento de gigas sin costo en lugar de un descuento en dinero.
- Para el cliente con quejas técnicas: Una visita técnica prioritaria.

2. Caso de Estudio 2: Mantenimiento Predictivo Industrial

Una planta industrial de alimentos congelados quiere predecir fallos en sus motores de refrigeración para evitar que la mercancía se pierda. Contratan a un equipo de científicos de datos para implementar una estrategia de Mantenimiento Predictivo, para lo cual realizan lo siguiente:

- Entendimiento de Datos (Big Data): El equipo de Data Engineering instala cientos de sensores que miden temperatura, vibración y consumo eléctrico cada segundo. Generan Terabytes de datos.
- Preparación de Datos: El equipo limpia los datos, maneja el ruido de los sensores y crea un sistema de streaming para procesar la información en tiempo real.
- Modelado: Entrenan una Red Neuronal Profunda diseñada para detectar anomalías. El modelo es capaz de predecir que un motor va a fallar con 24 horas de antelación con un 98 % de confianza.
- Despliegue: Se instala una alerta roja en la sala de control que se enciende cuando el modelo predice un fallo inminente.

2.1. Resultado

Durante el primer mes, la alarma sonó 10 veces. En las 10 ocasiones, los técnicos corrieron al motor, lo desarmaron y no encontraron nada roto. El motor funcionaba perfectamente. Sin embargo, el modelo insistía en que había una anomalía crítica. La gerencia decidió apagar el sistema por “generar falsas alarmas” y, una semana después, un motor se quemó sin previo aviso, causando pérdidas millonarias.

2.1.1. Error Cometido

A diferencia del caso anterior (que era un fallo de negocio), este es un fallo de Entendimiento de Datos y Contexto Interdisciplinario:

- El Fallo (Data Leakage / Contexto): El equipo de datos no habló con los mecánicos de la planta. Si lo hubieran hecho, habrían descubierto que los motores tienen un ciclo de descongelamiento automático cada 12 horas. Durante ese ciclo, la temperatura sube y la vibración cambia drásticamente.
- El Error del Modelo: El modelo identificó el ciclo de limpieza como una “anomalía” porque estadísticamente se veía diferente al funcionamiento normal.
- Por qué falló el motor real: Cuando el motor real iba a fallar, el modelo lanzó la alerta, pero los técnicos ya no confiaban en el sistema (Alarma Fatigue) y la ignoraron.

2.2. Solución Propuesta

Para resolver este caso, el equipo debe integrar la Ingeniería de Características (Feature Engineering) con el conocimiento experto:

- Etiquetado Contextual: Debieron añadir una variable (columna) al dataset llamada “Es Ciclo Mantenimiento (Sí/No)”. Esto le “explica” al modelo que ese comportamiento es normal en ciertos horarios.
- En la fase de Scrubbing (Limpieza) y Exploring, el científico de datos debe visualizar los picos de los datos y preguntar a los expertos: “¿Qué pasa en la planta todos los días a esta hora?”.

Actividad

Con sus propias palabras, ¿qué conclusiones puede obtener de los anteriores casos?