

Pacto Pedagógico

Curso SI3015 – Fundamentos de Aprendizaje Automático

Escuela de Ciencias Aplicadas e Ingeniería

Periodo académico 2026-2

Objetivo

Establecer un acuerdo entre el profesor y los estudiantes para alcanzar los objetivos del curso y fortalecer el proceso de formación académica.

Contenido

- **Revisión del programa:** Presentación de los propósitos, competencias, contenidos, metodología y evaluaciones del curso.
- **Cronograma de actividades:** Explicación de las fechas y modalidades de las evaluaciones y actividades principales
- **Dinámica del curso:** Descripción de las metodologías que se emplearán en las sesiones para desarrollar competencias y cumplir los resultados de aprendizaje.
- **Compromisos de los estudiantes:** Tareas y actividades como lecturas previas, informes, talleres y proyectos que deben realizarse.
- **Compromisos del profesor:** Responsabilidades específicas para facilitar el aprendizaje de los estudiantes.
- **Expectativas mutuas:** Establecimiento de responsabilidades y acuerdos para el trabajo conjunto.
- **Ambiente de respeto e inclusión:** Actividades para fomentar el respeto y la participación de todos los estudiantes.

Revisión del programa

Contenido del curso

El curso se organiza en cuatro módulos secuenciales, cada uno compuesto por sesiones presenciales de tres (3) horas, que integran fundamentos teóricos, desarrollo práctico y aplicaciones contemporáneas del Aprendizaje Automático. En resumen, a continuación se detalla el contenido del curso en términos generales:

Módulo 1: Fundamentos y Preparación de Datos

Este módulo sienta las bases teóricas y prácticas del aprendizaje automático. Se enfoca en entender el flujo de trabajo de un proyecto de IA y en las técnicas críticas de ingeniería de datos, necesarias para transformar datos brutos en información útil para el modelado.

■ Introducción al Ecosistema de la IA

- Definición y tipos de Aprendizaje Automático: Supervisado, No Supervisado y por Refuerzo.
- El ciclo de vida de un proyecto: Metodología CRISP-DM.
- Configuración del entorno técnico: Herramientas esenciales (Python, Jupyter, Pandas, NumPy).

■ Análisis Exploratorio de Datos (EDA)

- Estadística descriptiva aplicada y detección de anomalías (Outliers).
- Visualización de datos: Uso de Matplotlib y Seaborn para descubrir patrones y correlaciones.
- Análisis de la distribución y balanceo de clases.

■ Ingeniería de Características (Feature Engineering)

- Limpieza de datos: Tratamiento de valores nulos (Imputación).
- Transformación de variables: Escalado (Min-Max) y Estandarización (Z-score).
- Codificación de datos categóricos: One-Hot Encoding y Label Encoding.

■ Fundamentos de Evaluación

- División de datos: Entrenamiento, Validación y Test.
- Concepto de Overfitting (sobreajuste) y Underfitting (infraajuste).

Módulo 2: Aprendizaje Supervisado

Este módulo profundiza en los fundamentos del aprendizaje supervisado, explorando algoritmos que permiten predecir resultados continuos y categóricos. Se analiza desde la optimización de funciones de pérdida en modelos lineales hasta la potencia de los algoritmos basados en comités de árboles.

■ Regresión y Modelos Lineales

- Regresión Lineal Simple y Múltiple: Estimación por mínimos cuadrados y métricas de error.
- Regresión Logística: Modelado de probabilidades y funciones de activación sigmoide.
- Regularización (L_1 Lasso, L_2 Ridge): Técnicas para prevenir el sobreajuste (overfitting) mediante la penalización de coeficientes.

■ Árboles y Métodos de Ensemble: El poder de la colaboración

- Árboles de Decisión y Clasificación: Criterios de división y poda del árbol.
- Random Forests: Introducción al Bagging y la reducción de la varianza mediante el promediado de modelos independientes.
- Gradient Boosting (XGBoost/LightGBM): Aprendizaje secuencial y optimización de residuos para maximizar la precisión.

■ Máquinas de Soporte Vectorial (SVM)

- Maximización del margen y vectores de soporte.
- Introducción al "Kernel Trick" para la separación de datos en espacios no lineales.

■ Evaluación y Selección de Modelos

- El compromiso entre sesgo y varianza (Bias-Variance Tradeoff).
- Validación cruzada (K-Fold Cross Validation) y curvas de aprendizaje.

Módulo 3: Aprendizaje No Supervisado

Este módulo explora técnicas para descubrir patrones, estructuras y relaciones latentes en conjuntos de datos no etiquetados. Se centra en la segmentación inteligente y la simplificación de datos complejos mediante la reducción de la dimensionalidad, herramientas esenciales para la exploración de datos y la ingeniería de características.

■ **Clustering: Segmentación y Agrupamiento**

- K-Means: Particionamiento basado en centroides, selección de K mediante el método del codo (Elbow Method) y análisis de silueta.
- DBSCAN: Agrupamiento basado en densidad para la detección de clústeres de formas arbitrarias y puntos de ruido (outliers).
- Clustering Jerárquico: Enfoques aglomerativos, dendrogramas y métricas de distancia.

■ **Reducción de Dimensionalidad: Compresión y Visualización**

- Análisis de Componentes Principales (PCA): Maximización de la varianza y ortogonalización de características.
- t-SNE y UMAP: Técnicas avanzadas de reducción no lineal para la visualización de datos de alta dimensionalidad en 2D o 3D.
- Aplicaciones: Eliminación de redundancia, reducción de ruido y preparación de datos para modelos supervisados

■ **Detección de Anomalías y Aplicaciones Prácticas**

- Identificación de patrones inusuales en datos financieros o de seguridad.
- Sistemas de recomendación basados en filtrado colaborativo no supervisado.

Módulo 4: introducción a Aprendizaje por Refuerzo (Reinforcement Learning)

Este módulo introduce el paradigma del aprendizaje mediante la interacción activa con un entorno. A diferencia de los métodos supervisados, el enfoque aquí es la optimización de comportamientos a través de señales de recompensa, permitiendo que el agente aprenda estrategias complejas para la resolución de problemas dinámicos.

■ **Fundamentos y el Marco de Trabajo**

- Conceptos básicos: Agente, Entorno, Estado (s), Acción (a) y Recompensa (r).
- Procesos de Decisión de Markov (MDP): La base matemática del aprendizaje por refuerzo.
- El dilema entre Exploración vs. Explotación (Epsilon-Greedy)

■ Dinámica del Aprendizaje

- El bucle de retroalimentación: Observación, Decisión, Acción y Recompensa.
- Horizontes temporales: Tareas episódicas frente a tareas continuas.
- El factor de descuento (γ): Priorizando recompensas inmediatas vs. a largo plazo.

■ Optimización y Funciones de Valor

- Política Óptima (π^*): Determinando el mejor curso de acción en cada estado.
- Función de Valor de Estado $V(s)$ y Función Valor Estado-Acción $Q(s, a)$.
- Introducción a las Ecuaciones de Bellman para la iteración de valores.

■ Categorías y Algoritmos de Aprendizaje

- Aprendizaje basado en modelos (Model-Based) vs. libre de modelos (Model-Free).
- Métodos Clásicos: Q-Learning y SARSA (Diferencias temporales).
- Introducción al Deep Reinforcement Learning (DRL): El uso de redes neuronales como aproximadores de funciones (DQN)

Evaluación del curso

La evaluación del curso se estructura por módulos y combina instrumentos de evaluación formativa y sumativa, incluyendo cuestionarios, informes teórico-prácticos y un proyecto final integrador. La distribución porcentual y el cronograma de evaluación son los siguientes:

Módulo	Evaluación	%	Semana	Fecha
Módulo 1	Examen	10	Semana 4	3 al 7 de agosto
	Informe teórico-práctico	15	Semana 5	10 al 14 de agosto
Módulo 2	Examen	10	Semana 8	31 agosto al 4 de septiembre
	Informe teórico-práctico	15	Semana 9	7 al 11 de septiembre
Módulo 3	Examen	10	Semana 12	28 septiembre al 2 de octubre
	Informe teórico-práctico	15	Semana 13	12 al 16 de octubre
Módulo 4	Proyecto final e informe	25	Semana 16	2 al 6 de noviembre

Dinámica del curso

- Equipos de 3 (o 4) integrantes para la entrega del último módulo y el proyecto.
- Cualquier cambio en la dinámica o condiciones del proyecto debe ser validado por el profesor.
- Todo el equipo de trabajo debe estar presente durante las presentaciones del trabajo.
- La calificación es grupal, pero también se evalúa el aporte individual.
- El código se entrega por medio de GitHub preferiblemente en notebooks de python.
- El lenguaje de programación que usaremos en clase y en las actividades evaluativas será Python.
- Usaremos GitHub para gestionar el proyecto del semestre.
- La nota aprobatoria de las actividades y la asignatura es 3.0.
- No se realizan cambios de nota, a menos que el profesor haya cometido algún error.

Compromisos de los estudiantes

- Realizar y entregar las actividades en las fechas definidas.
- Aportar significativamente al equipo de trabajo.
- Realizar la evaluación al docente entre las semanas 12 y 15.
- Estar atento a sus calificaciones durante todo el semestre.
- Leer y seguir los lineamientos del reglamento, el cual está disponible en <https://www.eafit.edu.co/institucional/reglamentos/Documents/reglamento-academico-pregrado.pdf>.
- Comunicar dudas o sugerencias por medio del correo electrónico o Teams (pvallej3@eafit.edu.co).

Sobre la asistencia a clases

De acuerdo con el Artículo 46 del Reglamento Estudiantil actualizado en 2025 y vigente a partir de 2026, como directriz para la Escuela de Ciencias Aplicadas e Ingeniería y para el programa, el porcentaje de inasistencia a las clases que aplica para generar mecanismos de impacto en la evaluación será del **25 % de las horas programadas**.

Ejemplo: si el curso es de 48 horas presenciales, el estudiante podrá faltar a un máximo de 12 horas. A partir de este umbral se aplicarán, de manera proporcional o absoluta, los siguientes impactos en la evaluación:

- Si un estudiante falta a **12 horas o más** durante el desarrollo del curso, no podrá presentar el proyecto final, correspondiente al **25 % de la nota final**, y se le asignará una calificación de **0.0** en este componente.
- Si un estudiante falta entre **6 y 11 horas** de clase, podrá presentar el proyecto final; sin embargo, el **20 % correspondiente a este componente será penalizado de manera proporcional y lineal** en función del número total de horas de inasistencia acumuladas.

La nota efectiva del proyecto, expresada sobre el 20 %, se calculará mediante la siguiente expresión:

$$P(H) = 20 \times \left(1 - \frac{H - 6}{6} \right)$$

donde H corresponde al número total de horas de inasistencia del estudiante durante el curso. En consecuencia, con 6 horas de inasistencia no se aplicará penalización, mientras que con 12 horas o más se perderá la totalidad del 20 % asignado al proyecto final.

Para confirmar la asistencia, en cada sesión el docente tomará lista, y el estudiante deberá estar presente al menos durante el **90 % del tiempo de la clase** para que la sesión sea considerada como asistida, de acuerdo con la actividad pedagógica programada.

Uso de Inteligencia Artificial Generativa

El uso de herramientas de **Inteligencia Artificial Generativa** (por ejemplo, asistentes de programación, modelos de lenguaje, generadores de código o de texto) **está permitido** en el desarrollo de las actividades del curso, siempre que su uso sea **ético, responsable y transparente**.

Los estudiantes deberán:

- Utilizar las herramientas de IA generativa como **apoyo al aprendizaje**, y no como sustituto del razonamiento, la comprensión conceptual o el trabajo propio.
- **Declarar explícitamente** el uso de IA generativa en cada entrega, indicando qué herramientas fueron utilizadas y con qué propósito (por ejemplo, generación de ideas, asistencia en programación, depuración de código o redacción preliminar).
- Asumir la **responsabilidad total** sobre el contenido entregado, incluyendo su corrección técnica, conceptual y ética, independientemente del uso de herramientas de IA.
- Garantizar que el trabajo presentado cumple con los principios de **honestidad académica** y con el reglamento institucional vigente.

El uso de IA generativa que implique **plagio, dependencia total de la herramienta o falta de comprensión del trabajo entregado** será considerado una falta a la integridad académica y será tratado conforme al reglamento institucional.