

Parcial — Fundamentos de Machine Learning

Pipeline, procesamiento, regresión lineal, regularización, KNN, árboles y ensambles, métricas

Nombre: _____	Fecha: _____	Duración: 120 min
---------------	--------------	-------------------

Instrucciones

El parcial consta de 17 preguntas: 5 de selección múltiple (una sola respuesta correcta) y 12 de desarrollo, que incluyen aplicación de fórmulas, un ejercicio de emparejamiento y preguntas sobre el caso de estudio. Justifique sus respuestas cuando se le pida. Puede usar calculadora.

Caso de estudio: LaptopHub

LaptopHub es un marketplace de computadores portátiles usados. El equipo de datos quiere (1) predecir el precio de reventa de un portátil a partir de sus características, y (2) predecir si un portátil necesitará una reparación en los próximos 6 meses. A continuación se muestra una muestra del conjunto de datos (DataFrame de pandas):

id	RAM_GB	Almacenamiento_GB	Antigüedad_meses	Marca	Precio_USD
1	8	256	12	Dell	450
2	16	512	6	Apple	1200
3	4	128	36	HP	200
4	16	256	18	Lenovo	600
5	8	512	24	Dell	500
6	32	1024	3	Apple	2200
7	8	256	30	HP	300
8	16	512	12	Lenovo	750

Sección A — Selección múltiple (1 respuesta correcta)

Pregunta 1. Un modelo de regresión obtiene un error muy bajo en el conjunto de entrenamiento, pero un error muy alto en el conjunto de prueba. Este comportamiento se conoce como:

- a) Underfitting (subajuste), causado por un sesgo (bias) alto.
- b) Overfitting (sobreajuste), causado por una varianza alta.
- c) Regularización excesiva.
- d) Un problema de datos no balanceados.

Pregunta 2. ¿Cuál de las siguientes afirmaciones sobre regularización es correcta?

- a) Ridge (L2) puede llevar coeficientes exactamente a cero, por lo que hace selección de variables.
- b) Lasso (L1) puede llevar coeficientes exactamente a cero, por lo que puede eliminar variables del modelo.
- c) Elastic Net es equivalente a no aplicar ninguna regularización.
- d) La regularización siempre aumenta la complejidad del modelo.

Pregunta 3. ¿Cuál de las siguientes afirmaciones describe correctamente a KNN (K-Nearest Neighbors)?

- a) Es un algoritmo 'lazy' (perezoso): no construye un modelo explícito durante el entrenamiento.
- b) KNN no requiere escalar ni normalizar las variables, ya que es inmune a la escala.
- c) A mayor valor de k, mayor es el riesgo de sobreajuste (overfitting).
- d) KNN solo puede usarse para problemas de clasificación, nunca de regresión.

Pregunta 4. Sobre Bootstrap Aggregating (Bagging), ¿cuál afirmación es correcta?

- a) Entrena los modelos de forma secuencial, dando más peso a los errores del modelo anterior.
- b) Entrena los modelos de forma paralela e independiente, cada uno sobre una muestra bootstrap de los datos.
- c) Es la técnica que usa XGBoost para minimizar el residual del ensamble.
- d) Funciona mejor con modelos lineales que con árboles de decisión.

Pregunta 5. La variable 'Marca' del dataset de LaptopHub (Dell, Apple, HP, Lenovo) no tiene un orden natural y tiene pocas categorías. ¿Qué técnica de codificación es la más adecuada por defecto para usarla en un modelo de regresión lineal?

- a) Label Encoding, asignando un número entero a cada marca.
- b) One-Hot Encoding, creando una columna binaria por cada marca.
- c) Dejarla como texto, ya que sklearn la interpreta automáticamente.
- d) Ordinal Encoding, ordenando las marcas alfabéticamente.

Sección B — Desarrollo y aplicación de fórmulas

Pregunta 6 . Fundamentos y notación.

Considere únicamente las columnas numéricas del dataset LaptopHub (*RAM_GB*, *Almacenamiento_GB*, *Antigüedad_meses*) — no incluya 'Marca', ya que es texto y aún no ha sido codificada.

- a) ¿Cuántas muestras (*n*) y cuántas variables numéricas (*d*) hay en el dataset mostrado?

-
- b) Escriba el vector de características $\mathbf{x}^{(3)}$ correspondiente al portátil con *id* = 3, siguiendo la notación $\mathbf{x}^{(i)} \in \mathbb{R}^{(d \times 1)}$ vista en clase.
-

Pregunta 7 . Ejercicio de emparejamiento — Proceso para abordar un dataset.

Relacione cada etapa del proceso (columna izquierda) con la descripción que le corresponde (columna derecha), escribiendo la letra correcta en la tabla.

- a) Aplicar One-Hot Encoding o Standard Scaler para preparar las variables para el algoritmo.
- b) Eliminar valores nulos o imputar los datos faltantes.
- c) Entrenar el algoritmo (ej. árbol de decisión, regresión lineal) con los datos ya preparados.
- d) Calcular métricas como R^2 , Accuracy o la matriz de confusión sobre los datos de prueba.
- e) Seleccionar las variables más relevantes o eliminar columnas redundantes por alta correlación.

Etapa	Su respuesta (letra)
1. Limpieza	
2. Reducción de dimensionalidad	
3. Transformación	
4. Modelado	
5. Evaluación	

Pregunta 8 . Regresión lineal — producto punto.

Recuerde que $\hat{y} = w_0 + \sum w_j \cdot x_j = \mathbf{w}^T [\mathbf{x}; 1]$.

Un modelo de regresión lineal para predecir el precio (*Precio_USD*) usa los pesos $\mathbf{w} = [w_0=50, w_1=40, w_2=0.3, w_3=-5]$ sobre las variables [*RAM_GB*, *Almacenamiento_GB*, *Antigüedad_meses*]. Calcule $\hat{y}$ para el portátil con *id* = 8 (*RAM_GB*=16, *Almacenamiento_GB*=512, *Antigüedad_meses*=12), mostrando cada paso de la operación.

Pregunta 9 Transformación de datos — Min-Max Scaling.

Fórmula: $x_{scaled} = (x - x_{min}) / (x_{max} - x_{min})$

Para la columna Precio_USD del dataset completo, el valor mínimo es 200 y el valor máximo es 2200. Calcule el valor escalado (Min-Max, rango [0,1]) para el portátil con id = 4 (Precio_USD = 600).

Pregunta 10 Regularización Ridge.

Fórmula: $J(\beta) = MSE + \alpha \cdot \sum \beta_j^2$

a) Calcule el término de penalización ($\alpha \cdot \sum \beta_j^2$) para un modelo con coeficientes $\beta = [0.5, 0.8]$ y $\alpha = 10$.

b) Calcule el mismo término de penalización para coeficientes $\beta = [0.1, 10000]$ con el mismo $\alpha = 10$, y explique en 2-3 líneas por qué este resultado ilustra el objetivo de la regularización.

Pregunta 11 KNN — cálculo de distancia y clasificación.

Distancia euclídea: $d(X,Y) = \sqrt{(\sum (x_i - y_i)^2)}$

Se quiere clasificar un nuevo portátil según su 'nivel de consumo energético' usando dos variables: (RAM_GB, Antigüedad_meses). El nuevo punto es (12, 15). Los vecinos etiquetados son: A=(10,10) Bajo consumo; B=(20,5) Alto consumo; C=(8,20) Bajo consumo; D=(25,25) Alto consumo.

a) Calcule la distancia euclídea del nuevo punto a cada uno de los 4 vecinos.

b) Con k=3, ¿a qué clase se clasificaría el nuevo portátil? Justifique con base en el resultado del literal (a).

Pregunta 12 Árboles de decisión — Entropía.

Fórmula: $H(\pi_p, \pi_n) = -\pi_p \cdot \log_2(\pi_p) - \pi_n \cdot \log_2(\pi_n)$, donde $\pi_p = p/(p+n)$ y $\pi_n = n/(p+n)$.

En un nodo del árbol hay 8 portátiles: 6 'Sí necesitan reparación' (p=6) y 2 'No necesitan reparación' (n=2). Calcule la entropía H de ese nodo, mostrando el cálculo de π_p , π_n y el resultado final.

Pregunta 13 Ensamblados — Bagging.

Describa, en sus propias palabras, los dos pasos principales del algoritmo de Bagging si se aplicara para predecir si un portátil necesita reparación (paso 1: cómo se construye cada subconjunto de entrenamiento; paso 2: cómo se combina la predicción final de todos los modelos).

Pregunta 14 Métrica de regresión — R^2 (Coeficiente de Determinación).

Fórmula: $R^2 = 1 - SSR/SST$

Un modelo de regresión lineal entrenado para predecir Precio_USD obtiene, sobre el conjunto de prueba, $SSR = 750,000$ y $SST = 5,000,000$. Calcule el R^2 del modelo e interprete el resultado: ¿qué tan bueno es este modelo comparado con simplemente predecir el precio promedio para todos los casos?

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \quad SSR = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Pregunta 15 Métricas de clasificación — Matriz de confusión.

Fórmulas: $Accuracy = (TP+TN)/Total$; $Precision = TP/(TP+FP)$; $Recall = TP/(TP+FN)$

Un modelo de clasificación predice si un portátil necesita reparación ('Sí' = clase positiva). Sobre 200 portátiles de prueba se obtuvo la siguiente matriz de confusión: TP = 45, FP = 10, FN = 15, TN = 130.

a) Calcule Accuracy, Precision y Recall.

b) Para este caso de negocio, ¿qué es más costoso: un Falso Positivo o un Falso Negativo? ¿Qué métrica priorizaría al elegir el mejor modelo, Precision o Recall? Justifique.

Pregunta 16 Un estudiante de LaptopHub escribió el siguiente código para escalar el dataset:

```
scaler = MinMaxScaler()
X_scaled = scaler.fit_transform(X) # X es el dataset completo
X_train, X_temp = train_test_split(X_scaled, test_size=0.3)
X_val, X_test = train_test_split(X_temp, test_size=0.5)
```

a) ¿Qué error de diseño tiene este código?

b) ¿Cómo lo corregiría?

Pregunta 17 Complete el código:

```
numerical_processing = Pipeline([
    ('num_imputer', SimpleImputer(strategy='mean')),
    ('num_scaler', _____)
])

categorical_processing = Pipeline([
    ('cat_imputer', SimpleImputer(strategy='constant', fill_value='missing')),
    ('cat_encoder', _____)
])

processor = ColumnTransformer(transformers=[
    ('num_processing', numerical_processing, ['RAM_GB', 'Almacenamiento_GB', 'Antigüedad_meses']),
    ('cat_processing', categorical_processing, [_____])
])

pipeline = Pipeline([
    ('data_processing', _____),
    ('estimator', _____)
])

pipeline._____(X_train, y_train)
predictions = pipeline._____(X_test)
```

KNeighborsClassifier(), 'Marca', .predict, StandardScaler(), processor, .fit, OneHotEncoder(handle_unknown='ignore')

Fin del parcial. ¡Éxitos!