

# Lecture09: SVMs and SVR

Yomin E. Jaramillo Múnera  
EAFIT



# Contenido

1. SVM: clasificacion de margen maximo
2. Funcion de perdida Hinge y SVM como optimizacion
3. Extension a espacios de caracteristicas no lineales
4. SVR: regresion de margen maximo
5. Seleccion del hiperparametro C




# Support Vector Machine


Algoritmo de aprendizaje supervisado usado principalmente para clasificación, busca el hiperplano que separa las clases con el margen máximo entre ellas, apoyándose únicamente en los puntos más cercanos a la frontera (los "vectores de soporte")




# Clasificación lineal



# Aprendizaje como optimizacion



# Clasificación lineal: Margen



# Margen amplio como optimizacion

- ❖ Función de pérdida

$$\text{Loss}_h(y^{(i)}(\theta \cdot x^{(i)} + \theta_0)) =$$

- ❖ Regularización: Buscando un margen amplio
- ❖ La función objetivo

$$J(\theta, \theta_0) = \frac{1}{n} \sum_{i=1}^n \text{Loss}_h(y^{(i)}(\theta \cdot x^{(i)} + \theta_0)) + \frac{\lambda}{2} \|\theta\|^2$$



# Hinge loss

$$\text{Loss}(y^{(i)} (\theta \cdot \mathbf{x} + \theta_0)) = \max\{0, 1 - y^{(i)} (\theta \cdot \mathbf{x} + \theta_0)\}$$



# SVM - Support Vector Machine


- SVMs hallan el maximo margen lineal de separacion resolviendo el problema cuadratico que corresponde a  $J(\theta, \theta_0)$
- En el caso realizable, si no permitimos que ninguna muestra este por dentro del margen, el problema de programacion cuadratica a resolver es el siguiente:

$$\underset{(\theta, \theta_0)}{\text{minimize}} \quad \frac{1}{2} \|\theta\|^2 \quad \text{subject to}$$


$$y^{(i)} (\theta \cdot x^{(i)} + \theta_0) \geq 1, \quad i = 1, \dots, n$$





# Clasificadores lineales en el eje real



# En un espacio de características



# Ejemplo en 2D



# Clasificación y regresión no lineales

- Clasificación no lineal

$$h(x; \theta, \theta_0) = \text{sign}(\theta \cdot \phi(x) + \theta_0)$$

- Regresión no lineal

$$f(x; \theta, \theta_0) = \theta \cdot \phi(x) + \theta_0$$

$$\phi(x) = [x, x^2]^T$$




# Support Vector Regressor

Es la extensión de SVM al problema de regresión. En vez de buscar un hiperplano que separe clases, busca una función que se ajuste a los datos dentro de un margen de tolerancia  $\epsilon$  (épsilon)



# Regresion lineal

$$\text{MIN} \sum_{i=1}^n (y_i - w_i x_i)^2$$




OLS Prediction of Boston Housing Prices




$$\text{MIN } \frac{1}{2} ||\mathbf{w}||^2$$


$$|y_i - w_i x_i| \leq \varepsilon$$



# SVR



Illustrative Example of Simple SVR




SVR Prediction of Boston Housing Prices with  $\epsilon=5$



# SVR

$$\text{MIN } \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n |\xi_i|$$



$$|y_i - w_i x_i| \leq \varepsilon + |\xi_i|$$



SVR Prediction of Boston Housing Prices with  $\epsilon=5$ ,  $C=1.0$



# Encontrar mejor valor para C



SVR Prediction of Boston Housing Prices with  $\epsilon=5$ ,  $C=6.13$

