

SHAP y Clustering K-Means

Fundamentos de Aprendizaje Automático

Yomin E. Jaramillo Múnera
EAFIT



Agenda

1. Explicabilidad en Machine Learning
2. SHAP (SHapley Additive exPlanations)
3. Aprendizaje no supervisado
4. Clustering: algoritmo K-Medias





¿Por qué explicabilidad?

- No confiamos plenamente en los modelos
- No sabemos qué pasa en casos extremos
- Los errores pueden ser costosos o nocivos
- ¿Los modelos cometen errores similares a los humanos?
- ¿Cómo corregimos un modelo que no da los resultados esperados?



*La interpretabilidad busca abrir
la “caja negra” del modelo*


**Una forma de abordar estos problemas es la
interpretabilidad**



Problemas: sesgos algorítmicos

- Un estudio de 2018 evaluó la precisión de un sistema comercial de análisis facial en distintos grupos demográficos.
- La precisión cayó notablemente para el grupo de mujeres de piel oscura, evidenciando un sesgo en los datos de entrenamiento.

August 2018 Accuracy on Facial Analysis Pilot Parliaments Benchmark



Amazon Rekognition Performance on Gender Classification

Machine Learning can amplify bias.




- Data set: 67% of people cooking are women
- Algorithm predicts: 84% of people cooking are women



Problemas: ejemplos adversarios

- Pequeñas perturbaciones, imperceptibles para el ojo humano, pueden cambiar por completo la predicción de un modelo.
- Esto revela que el modelo puede apoyarse en patrones distintos a los que usaría una persona.



Misma imagen para el ojo humano; predicción totalmente distinta para el modelo.



Hacia un ML interpretable

Tenemos varios problemas:

- No confiamos en los modelos
- No sabemos qué pasa en casos extremos
- Los errores pueden ser costosos o nocivos
- ¿Los modelos cometen errores similares a los de los humanos?
- ¿Cómo cambiamos el modelo si no da los resultados esperados?

Una forma de lidiar con estos problemas es a través de la interpretabilidad



Definiciones clave: explicabilidad

- **Interpretabilidad:** Grado en que un humano puede entender la causa de una decisión del modelo.
- **Modelo caja negra:** Modelo cuyo funcionamiento interno no es directamente comprensible.
- **Explicación global:** Describe el comportamiento general del modelo en todo el conjunto de datos.
- **Explicación local:** Describe por qué el modelo dio una predicción para una instancia específica.
- **Importancia de característica:** Cuánto aporta cada variable de entrada a una predicción.



SHapley Additive exPlanations – SHAP

- SHAP es un método unificado para interpretar las predicciones de cualquier modelo de Machine Learning.
- Se basa en los valores de Shapley, un concepto de teoría de juegos cooperativos (Lloyd Shapley, 1953).
- Asigna a cada característica una contribución justa a la predicción final.


“A Unified Approach to Interpreting Model Predictions”

Scott M. Lundberg & Su-In Lee — University of Washington (NeurIPS, 2017)



La analogía del juego cooperativo

- Un equipo de jugadores colabora para obtener un premio (payout) en una competencia.
- ¿Cuál es una forma justa de repartir ese premio entre los jugadores según su aporte?




Contribución: cuánto aporta cada jugador al resultado del equipo.



SHAP aplicado a un modelo de ML

- La misma idea se traslada a un modelo: las características (features) son los “jugadores”.
- El “payout” es la predicción del modelo para una instancia dada.

Características de un modelo



El valor de Shapley

$$\phi_i(f, \mathbf{x}) = \sum_{\mathbf{z}' \subseteq \mathbf{x}'} \frac{|\mathbf{z}'|!(M - |\mathbf{z}'| - 1)!}{M!} [f(\mathbf{z}') - f(\mathbf{z}' \setminus i)]$$


- $\mathbf{z}'$: subconjunto de características activas
- $\mathbf{z}' \setminus i$: el mismo subconjunto, sin la característica i
- $f(\mathbf{z}') - f(\mathbf{z}' \setminus i)$: contribución marginal de la característica i en ese subconjunto

$\mathbf{x}'$	Age = 56	Gender = F	BMI = 30	Heart disease = yes	...
$\mathbf{z}'$	Age = 56	Gender = F	BMI = 30	Heart disease = yes	...



¿Cuántas combinaciones hay que evaluar?


- SHAP evalúa, en principio, todos los subconjuntos posibles de características para calcular la contribución marginal de cada una.
- El número total de subconjuntos de un conjunto con n elementos es 2^n .



Con 10 características ($n=10$) existen $2^{10} = 1024$ subconjuntos posibles — por eso SHAP usa aproximaciones eficientes en la práctica.



Aprendizaje No supervisado



Tipos de aprendizaje en ML

Supervisado

Aprende de datos etiquetados para predecir una salida conocida.

No supervisado

Encuentra estructura en datos sin etiquetas.

Por refuerzo

Aprende mediante prueba y error, maximizando una recompensa.

Desde ahora nos enfocamos en aprendizaje no supervisado.



Aprendizaje no supervisado

- No contamos con etiquetas a predecir, pero podemos tomar decisiones sobre los datos mediante aprendizaje automático.

Tareas más comunes:

Hoy veremos esto

Agrupamiento (clustering)

Encontrar grupos naturales de datos similares.

Reducción de dimensionalidad

Representar los datos con menos variables.


Detección de anomalías

Identificar observaciones atípicas.



Agrupamiento (clustering)

- Encontrar etiquetas (labels) para objetos que no las tienen.
- Es el proceso de particionar un conjunto de datos en subconjuntos (clusters) de puntos similares entre sí.



Algoritmo K-Means

Inicializar los centros: $k = \{ c_1^{\rightarrow}, c_2^{\rightarrow}, \dots, c_k^{\rightarrow} \}$

1

Para cada centro, encontrar los datos más cercanos.

2


Recalcular el centro sacando la media de los puntos en el cluster.

3

Repetir desde el paso 1 hasta que los centros dejen de cambiar.



Algoritmo K-Medias



<https://www.youtube.com/watch?v=5l3Ei69l40s>



K-Means: función objetivo

- El procedimiento de K-Means equivale a minimizar la inercia: la desviación o dispersión del conjunto de datos con respecto a los centros.


$$\arg \min_{\mathbf{S}} \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

S: partición en k clusters · μ_i : centro (centroide) del cluster i · se busca la partición que minimiza la suma de distancias al cuadrado.






K-Medias: criterio del codo

- Para decidir el número de clusters k se puede usar el criterio del codo: se grafica la dispersión promedio contra k y se busca el punto donde la mejora deja de ser significativa.



K-Medias: desventajas

- No garantiza encontrar el agrupamiento óptimo (depende de la inicialización).
- Depende de la métrica de distancia utilizada.
- Es sensible a valores atípicos (outliers).
- Presenta problemas cuando los datos tienen muchas dimensiones.
- Asume clusters de forma aproximadamente esférica y tamaño similar.



Definiciones clave: clustering

- **Cluster:** Grupo de observaciones similares entre sí y distintas de las de otros grupos.
- **Centroide:** Punto que representa el centro (la media) de un cluster.
- **Inercia / dispersión:** Suma de distancias al cuadrado entre cada punto y el centro de su cluster.
- **k:** Número de clusters que el algoritmo debe encontrar, definido antes de ejecutarlo.



¡Muchas gracias!

Referencias

- Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.
- Buolamwini, J. & Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification.
- Material de curso: Fundamentos de Aprendizaje Automático, Universidad EAFIT.

