

Clustering y Reducción de Dimensionalidad

Fundamentos de Aprendizaje Automático

Yomin E. Jaramillo Múnera
EAFIT




Agenda

1. Clustering: Dbscan
2. Clustering: Hierarchical Clustering
3. Reducción de dimensionalidad: PCA



Agrupamiento (clustering)

- Encontrar etiquetas (labels) para objetos que no las tienen.
- Es el proceso de particionar un conjunto de datos en subconjuntos (clusters) de puntos similares entre sí.




CLUSTERING: DBSCAN

- También llamado clustering basado en densidad

DBSCAN = Density-Based Spatial Clustering of Applications with Noise

Un punto pertenece a un cluster si está cerca de muchos otros puntos de ese cluster. Las regiones de alta densidad se separan de las de baja densidad, que se consideran ruido.




k-means clustering



DBSCAN: parámetros eps y minPts

- eps (ϵ): distancia máxima para que dos puntos se consideren vecinos.
- minPts: número mínimo de puntos (incluyéndose a sí mismo) que debe haber dentro del radio eps para considerar esa zona como densa.



En este ejemplo:

P tiene 5 vecinos dentro de su radio eps (+ él mismo = 6).


Si $\text{minPts} \leq 6$, P es un punto núcleo (core point).

“The main idea behind DBSCAN is that a point belongs to a cluster if it is close to many points from that cluster.”



DBSCAN: tipos de puntos

- **Punto núcleo (core)**
Tiene al menos minPts vecinos dentro de su radio eps.
- **Punto de borde (border)**
Está dentro del radio eps de un punto núcleo, pero no tiene suficientes vecinos propios.
- **Ruido (noise)**
No es núcleo ni es alcanzable desde ningún núcleo.



DBSCAN: tipos de puntos

1

Elegir un punto no visitado al azar y calcular su vecindad con radio eps.

2

Si tiene $\geq \text{minPts}$ vecinos (incluyéndose), es un punto núcleo: se crea o se expande un cluster.

3


Todos los puntos de su vecindad se agregan al cluster; si alguno también es núcleo, su vecindad también se expande (encadenamiento por densidad).

4

Si no tiene suficientes vecinos, se marca como ruido (puede reclasificarse luego si resulta ser borde de otro cluster).


5

Se repite con el siguiente punto no visitado, hasta visitar todos los puntos.



DBSCAN: eligiendo eps y minPts

- minPts: una regla práctica es $\text{minPts} \geq D + 1$, donde D es el número de dimensiones (con datos ruidosos, $\text{minPts} = 2 \times D$ suele funcionar mejor).
- eps: se calcula la distancia de cada punto a su k -ésimo vecino más cercano ($k = \text{minPts}$) y se grafica en orden descendente — el gráfico de k -distancias.
- El valor de eps se elige en el “codo” de esa curva: el punto donde la distancia empieza a crecer rápidamente separa puntos densos de puntos dispersos.



Puntos ordenados por k -distancia (descendente)



DBSCAN: ventajas y desventajas

Ventajas

- No requiere definir el número de clusters de antemano.
- Encuentra clusters de forma arbitraria (no solo esféricos).
- Identifica y es robusto ante outliers/ruido.


Desventajas

- Sensible a la elección de ϵ y minPts.
- Dificultad con clusters de densidad muy variable.
- Se degrada en datos de alta dimensionalidad.




CLUSTERING: Hierarchical

- No requiere definir k de antemano: construye una jerarquía completa de clusters anidados.
- Esa jerarquía se representa como un árbol llamado dendrograma.
- Dos enfoques posibles:
 - ▶ Aglomerativo (bottom-up): cada punto empieza solo y se van fusionando los más cercanos. El más usado en la práctica.
 - ▶ Divisivo (top-down): todos los puntos empiezan en un único cluster que se va dividiendo.



Clustering jerárquico aglomerativo


- 1 Cada punto empieza como su propio cluster (n clusters iniciales).
- 2 Se calcula la distancia entre todos los pares de clusters.
- 3 Se fusionan los dos clusters más cercanos en uno solo.
- 4 Se repite el paso 2 y 3 hasta que todos los puntos queden en un único cluster.



El resultado es el dendrograma completo, del cual luego se elige dónde “cortar”.



Clustering jerárquico aglomerativo




	Combined clusters (at this level)	All clusters	Total Number of Clusters
Start	None	2, 3, 6, 8, 12, 16, 34, 35, 50	9
Level 1	(2 - 3), (34 - 35)	(2 - 3), (34 - 35), 6, 8, 12, 16, 50	7
Level 2	(6 - 8)	(2 - 3), (34 - 35), (6 - 8), 12, 16, 50	6
Level 3	[(2-3) - (6-8)], (12 - 16)	[(2-3) - (6-8)], (12 - 16), (34 - 35), 50	4
Level 4	[(2-3) - (6-8) - (12 - 16)]	[(2-3) - (6-8) - (12 - 16)], (34 - 35), 50	3
Level 5	[(2-3) - (6-8) - (12 - 16) - (34-35)]	[(2-3) - (6-8) - (12 - 16) - (34-35)], 50	2
Level 6	All	All	1



El dendrograma

- Cada fusión se representa como una “U” que une dos ramas a la altura de la distancia a la que se fusionaron.
- Mientras más baja la fusión, más similares son esos puntos/clusters entre sí.



Criterios de enlace (linkage)

- ¿Cómo se mide la “distancia entre dos clusters” (no entre dos puntos)? Eso lo define el criterio de enlace.

Single (mínimo)

La distancia entre los dos puntos más cercanos de cada cluster.

Sensible a outliers; puede encadenar clusters (efecto cadena).

$$d_{\text{single}}(A, B) = \min_{a \in A, b \in B} d(a, b)$$

Complete (máximo)

La distancia entre los dos puntos más lejanos de cada cluster.

Produce clusters más compactos y balanceados.

$$d_{\text{complete}}(A, B) = \max_{a \in A, b \in B} d(a, b)$$

Average (promedio)

El promedio de las distancias entre todos los pares de puntos.

Compromiso entre single y complete.

$$d_{\text{average}}(A, B) = \frac{1}{|A| \cdot |B|} \sum_{a \in A} \sum_{b \in B} d(a, b)$$

Ward


Minimiza el incremento de la varianza intra-cluster al fusionar.

Suele dar los mejores resultados en la práctica; el más usado por defecto.

$$d_{\text{ward}}(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \cdot \|\mu_A - \mu_B\|^2$$



Criterios de enlace (linkage)




Complete (Max) and Single (Min) Linkage



Cortar el dendrograma

- El número de clusters k se decide después de construir el árbol completo, no antes.
- Se traza una línea horizontal a cierta altura; el número de ramas que corta esa línea es el número de clusters resultante.



Clustering jerárquico: ventajas y desventajas

Ventajas

- No necesita definir k a priori.
- El dendrograma da información visual rica sobre la estructura a distintas escalas.
- Funciona con cualquier métrica de distancia.

Desventajas

- Costoso computacionalmente ($O(n^2)$ o peor) , no escala bien a datasets grandes.
- El enlace simple es sensible a outliers (efecto cadena).
- Dónde cortar el árbol es, en parte, una decisión subjetiva.



Comparación: K-Medias, DBSCAN y Jerárquico

	K-Medias	DBSCAN	Jerárquico
¿Requiere k?	Sí	No	No (se decide al cortar)
Forma de clusters	Esférica	Arbitraria	Arbitraria
Maneja ruido/outliers	No	Sí	No directamente
Escalabilidad	Buena	Buena	Limitada ($O(n^2)$)
Determinístico	No (depende de init.)	Sí	Sí




REDUCCIÓN DE DIMENSIONALIDAD:

Como su nombre lo indica, busca llevar un conjunto de variables :

$$x_1, \dots, x_n$$


a una representación más pequeña de ellas:

$$z_1, \dots, z_k, \quad k < n$$



REDUCCIÓN DE DIMENSIONALIDAD: PCA

Es un método para reducir la dimensionalidad de los datos conservando las direcciones que mayor varianza tienen.




REDUCCIÓN DE DIMENSIONALIDAD: PCA

1. Calcular la media de cada variable.
2. Centrar los datos para que tengan media cero.
3. Calcular la matriz de covarianza.
4. Encontrar la descomposición en valores singulares.
5. Elegir el número de variables a conservar.
6. Proyectar.



REDUCCIÓN DE DIMENSIONALIDAD: PCA

En general, PCA no preserva clusters a la hora de reducir la dimensionalidad de los datos.



¡Muchas gracias!

Referencias

- Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.
- Buolamwini, J. & Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification.
- Material de curso: Fundamentos de Aprendizaje Automático, Universidad EAFIT.

