

Workshop1 —Machine Learning

Unidad 1

Análisis Exploratorio de Datos (EDA) con NumPy y Pandas

Objetivo

Aplicar el ciclo completo de exploración de datos: reconocimiento inicial, limpieza (cleaning), análisis descriptivo y visualización, usando un dataset real de Kaggle.

Instrucciones generales

- Trabajo en equipos de 3-4 personas.
- Cada equipo recibirá un dataset diferente (mismo nivel de dificultad).
- El entregable es un notebook (Jupyter/Colab) con código y celdas de texto (markdown) explicando cada hallazgo no basta con correr el código, hay que interpretar lo que se observa, y reconocer insights
- No se permite eliminar filas/columnas sin justificar por qué.

Bases de datos de trabajo

<https://www.kaggle.com/competitions/titanic/data?select=train.csv>

<https://www.kaggle.com/datasets/unsdsn/world-happiness>

<https://www.kaggle.com/datasets/gregorut/videogamesales>

<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>

<https://www.kaggle.com/datasets/ulrikthyegepedersen/airbnb-listings>

<https://www.kaggle.com/datasets/sujay1844/used-car-prices>

<https://www.kaggle.com/datasets/dhruvildave/spotify-charts>

<https://www.kaggle.com/datasets/CooperUnion/anime-recommendations-database>

Fase 1 — Reconocimiento inicial del dataset

1. Lea la documentación del dataset, y reconozca cual es su tema de trabajo
2. Cargue el dataset con pandas y muestre las primeras y últimas 5 filas (head(), tail()).
3. Indique cuántas filas y columnas tiene el dataset (.shape) y qué representa cada una (diccionario de datos: nombre de columna + tipo de dato esperado).
4. Use .info() y .dtypes para identificar qué columnas son numéricas, categóricas o de fecha.
5. Use .describe() para las columnas numéricas. Interprete al menos 3 estadísticos (media, desviación estándar, mínimo/máximo) en términos del problema (no solo el número).
6. Convierta al menos una columna numérica a un array de NumPy (.values o .to_numpy()) y calcule manualmente con funciones de NumPy (no pandas) su media, mediana y desviación estándar (np.mean, np.median, np.std).

Fase 2 — Limpieza de datos (Data Cleaning)

7. Identifique valores nulos por columna (.isnull().sum()) y calcule qué porcentaje representan del total de filas.
8. Proponga y justifique una estrategia de tratamiento para los nulos encontrados (eliminar filas, imputar con media/mediana/moda, imputar con un valor constante, etc.). Aplíquela.

9. Identifique y elimine filas duplicadas si existen (.duplicated(), .drop_duplicates()). Reporte cuántas se eliminaron.
10. Revise si hay inconsistencias de formato en columnas categóricas o de texto (ej. "Yes"/"yes"/"YES", espacios extra, mayúsculas/minúsculas) usando .unique() y corrijalas.
11. Identifique posibles valores atípicos (outliers) en al menos una columna numérica usando el criterio de rango intercuartílico (IQR). No es obligatorio eliminarlos, pero sí reportarlos. Para este punto hago el reporte manual basándose en las operaciones vistas en clase

Fase 3 — Exploración y análisis descriptivo

12. Usando .unique() y/o .value_counts(), identifique las categorías presentes en al menos dos columnas categóricas y cuántos registros tiene cada una.
13. Construya un diccionario donde la clave sea una categoría relevante del dataset y el valor sea una métrica agregada (promedio, conteo, máximo, etc.) calculada solo para un subconjunto filtrado de los datos (similar al ejercicio de tipo de dolor de pecho visto en clase).
14. Use .groupby() para responder al menos dos preguntas de negocio/análisis específicas del dataset asignado (ej. "¿Cuál es el promedio de X según la categoría Y?").
15. Ordene el dataset (.sort_values()) para identificar los 5 registros más altos y los 5 más bajos según una variable numérica relevante. Interprete brevemente qué representan esos extremos.

Fase 4 — Visualización (EDA gráfico)

Para cada gráfica, incluya el código, la imagen generada, y un párrafo de interpretación (qué observa, qué le sugiere sobre los datos), y cuál sería su recomendación como persona encargada de la toma de decisiones:

16. **Gráfico de barras:** distribución de una variable categórica relevante.
17. **Gráfico de pie:** proporción de una variable categórica binaria o con pocas categorías.
18. **Histograma:** distribución de una variable numérica. Indique si es simétrica o sesgada.
19. **Scatter plot:** relación entre dos variables numéricas. Indique si observa correlación (positiva, negativa o nula).
20. **Boxplot:** para al menos una variable numérica, generado con .boxplot() o seaborn. Identifique visualmente si hay outliers y relaciónelo con lo encontrado en el numeral 10.
21. **Gráfico de líneas (plot convencional):** *solo si el dataset tiene una variable temporal* (fecha, año, mes). Si no aplica, reemplace por un segundo boxplot comparando la variable numérica principal entre 2 o más categorías (ej. boxplot de precio por género).

Fase 5 — Conclusiones

22. Redacte un párrafo de conclusiones generales: ¿qué aprendió del dataset?, ¿qué variables parecen más relevantes?, ¿qué limpieza fue necesaria y por qué?, ¿qué preguntas quedarían abiertas para un futuro modelo de Machine Learning sobre estos datos?, use un subplot (2,2) con los gráficos que considere mas importantes para explicar sus hallazgos generales.

Entregable

Notebook (.ipynb) por equipo, subido a un repositorio de GitHub, ud solo debe poner el link del repo en interactiva.

Nota: *Este workshop será sustentado por algunos estudiantes de forma aleatoria, estos estudiantes sustentaran en nombre de su equipo y su nota de sustentación será tomada en cuenta así:*

$$(Sustentacion + Entrega) / 2$$